



**INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE  
MONTERREY**

**BI2009B. Procesamiento de imágenes médicas para el diagnóstico**

**Evidencia: Reporte formal actividad: Diagnóstico por Computadora**

**Profesor:** Dr. José Gerardo Tamez Pena

**Equipo 3**

**Integrantes:**

Astrid Geraldine Serna Zazueta      A01198214

Roberto Rodriguez Sanchez      A00835042

Juan Jose Robalino Romo Leroux      A00832934

Naomi De la Cruz García      A00572343

**31 de mayo del 2024**

Monterrey, Nuevo León

<b>Introducción.....</b>	<b>3</b>
<b>Marco teórico.....</b>	<b>3</b>
K-nearest Neighbors (KNN).....	4
Least Absolute Shrinkage and Selection Operator (LASSO).....	5
Naive Bayes (NB).....	5
<b>Materiales y métodos.....</b>	<b>5</b>
<b>Resultados y discusión.....</b>	<b>7</b>
Segmentación de Lesiones de Piel.....	7
Extracción de Características.....	9
Señal.....	9
Forma.....	12
Textura.....	13
Dimensiones Fractales.....	16
Algoritmos de aprendizaje supervisado.....	18
<b>Conclusiones.....</b>	<b>21</b>
Naomi De la Cruz García.....	21
Juan Jose Robalino Romo Leroux.....	21
Astrid Geraldine Serna Zazueta.....	22
Roberto Rodríguez Sanchez.....	22
<b>Referencias.....</b>	<b>22</b>

## **Introducción**

El cáncer de piel es uno de los tipos de cáncer más comunes en el mundo, siendo el melanoma la forma más maligna. Este tipo de cáncer se origina por la proliferación anormal de melanocitos. Las posibilidades de curar el melanoma aumentan significativamente si se diagnostica a tiempo, por lo que la detección temprana es crucial para un tratamiento exitoso. Sin embargo, el diagnóstico visual puede resultar difícil. La clasificación automatizada de imágenes mediante aprendizaje automático se ha convertido en una poderosa herramienta para ayudar a los dermatólogos a clasificar las lesiones cutáneas y detectar el melanoma con mayor precisión (González-Cruz et al., 2020).

En este estudio se evaluaron cuatro algoritmos diferentes de aprendizaje automático: KNN, SVM, LASSO y Naive Bayes, utilizando una base de datos de imágenes de lesiones cutáneas para clasificar si eran melanomas o no. Los algoritmos de aprendizaje automático pueden facilitar la detección temprana de enfermedades, reduciendo la carga de trabajo de los especialistas y mejorando el diagnóstico. Por ello, es crucial resaltar la importancia de los sistemas basados en aprendizaje automático, una rama de la inteligencia artificial con múltiples aplicaciones que ha evolucionado rápidamente en los últimos años (Bhatt et al., 2023).

## **Objetivos**

El objetivo de la siguiente actividad es evaluar y reportar el desempeño de la clasificación de diferentes imágenes de Melanoma mediante Aprendizaje por Computadora.

Objetivos específicos:

- Aplicar cuatro algoritmos diferentes de aprendizaje supervisado: KNN, SVM, LASSO y NB para la clasificación de melanomas y otro tipo de lesiones de acuerdo a sus características radiómicas.
- Evaluar los algoritmos de aprendizaje mediante matrices de confusión de sensibilidad, especificidad y F1, al igual que curvas ROC.

## **Marco teórico**

La piel es el órgano más grande del cuerpo, el cual protege al cuerpo de agentes externos, como agentes químicos y físicos, así como microorganismos (Proksch et al., 2008).

La piel protege al cuerpo de los rayos ultravioleta del sol. No obstante, este tipo de radiación está relacionada al desarrollo de cáncer en la piel, como carcinoma de células basales, carcinoma de células escamosas y melanoma maligno (D’Orazio et al., 2013). Dado esto, de los principales desafíos dentro del área médica es distinguir entre lesiones benignas de cáncer de piel melanoma y no melanoma (Curti et al., 2022).

Los melanomas son un tipo de cáncer causado por la proliferación de melanocitos anormales (Rigel & Carucci, 2000). Es causado por factores genéticos y ambientales, como la exposición a la radiación ultravioleta, la edad, género y el color de piel. Los melanomas se originan comúnmente en la piel; sin embargo, también se puede originar en otras partes del cuerpo, cómo la mucosa de la boca y los ojos (Esteve, 2007).

El aprendizaje por computadora se refiere a algoritmos diseñados para realizar predicciones más eficientes y precisas en tareas específicas. Estos algoritmos son entrenados a partir de datos o experiencias pasadas, lo que les permite mejorar su rendimiento y precisión (Mohri et al., 2018). El aprendizaje supervisado se basa en el entrenamiento de un modelo con entradas conocidas y valores de salida para predecir futuros valores, usando técnicas de clasificación y regresión. Algunos ejemplos de algoritmos de aprendizaje supervisado son (Choudhary & Gianey, 2017; Osisanwo et al., 2017; Sen et al., 2019):

#### *K-nearest Neighbors (KNN).*

Este algoritmo clasifica los datos de acuerdo a su similitud entre los K vecinos más cercanos en los datos de entrenamiento. Para realizar predicciones, almacena todos los datos de entrenamiento y, cuando hay un nuevo dato de entrada, calcula la distancia entre este nuevo dato y todos los puntos de entrenamiento. Después, selecciona los K puntos más cercanos y determina la clase del nuevo dato mediante una relación de las clases de estos K vecinos cercanos (Choudhary & Gianey, 2017).

#### *Support Vector Machines (SVM).*

Algoritmo utilizado para la clasificación y regresión de datos. Representa elementos de un conjunto de datos como puntos en un espacio n-dimensional, los cuales se dividen en clases en un hiperplano. Los elementos de datos se ubican para predecir la categoría a la cual pertenecen, de acuerdo al hiperplano en el que se encuentren (Sen et al., 2020).

### *Least Absolute Shrinkage and Selection Operator (LASSO).*

Es un algoritmo utilizado para la regularización en modelos de regresión lineal. Es particularmente útil para conjunto de datos de alta dimensión con muchas características. Este algoritmo agrega un término de penalización a la suma de residuos al cuadrado, promoviendo modelos con menos coeficientes no nulos, lo que mejora la precisión de las predicciones y la interpretabilidad del modelo (Muthukrishnan & Rohini, 2016).

### *Naïve Bayes (NB).*

Las redes Bayesianas estiman la independencia entre las características de una clase, por lo que se utilizan para tareas que implican clasificación de datos. Este algoritmo determina la probabilidad posterior de una clase basándose en la distribución de palabras dentro de un documento (Saravanan & Sujatha, 2018).

En el área médica, el aprendizaje por computadora ha sido ampliamente aplicado para el diagnóstico y predicción de enfermedades, por ejemplo, para la clasificación de cáncer de piel (Esteva et al., 2017) y predecir la progresión de pre-diabetes a diabetes tipo 2 (Anderson et al., 2016). Por ejemplo, la dermatoscopia es un método de diagnóstico no invasivo para el análisis de imágenes magnificadas de lesiones cutáneas pigmentadas (Palacios-Martínez & Díaz-Alonso, 2017). Este método permite analizar características como la asimetría, bordes y colores, haciendo uso de redes neuronales y modelos de aprendizaje automático para clasificar las lesiones (Celebi et al., 2019; Senan & Jadhav, 2021).

## **Materiales y métodos**

Para la elaboración del código se extrajo una base de datos de melanoma y posteriormente se desarrolló en el software RStudio, en su versión 4.3.3. La base de datos contenía características de melanoma, queratosis seborreica y nevus, al igual que grupos control para cada una de las categorías, por lo que el primer paso fue cargar los datos para utilizarse en el código.

```

MelanomaFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento de imagen
SeborrheicFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento de imag
NevusFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento de imagenes/
MelanomaControlFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento de
SeborrheicControlFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento
NevusControlFeatures <- read.csv("C:/Users/Astrid/Desktop/6to semestre/Procesamiento de im

```

*Fig 1. Loading data sets.*

Una vez que se cargaron los datos, se realizó el condicionamiento de los mismos, para garantizar que los datos que entrenan la señal puedan proporcionar resultados precisos y confiables. La imagen que se presenta a continuación es un ejemplo de lo que se realizó, se repitió el mismo procedimiento con cada una de las categorías.

```

op <- par(no.readonly = TRUE)

colnames(MelanomaControlFeatures) <- paste("C",colnames(MelanomaControlFeatures),sep="")
colnames(SeborrheicControlFeatures) <- paste("C",colnames(SeborrheicControlFeatures),sep="")
colnames(NevusControlFeatures) <- paste("C",colnames(NevusControlFeatures),sep="")

sum(is.na(MelanomaFeatures))
sum(is.na(SeborrheicFeatures))
sum(is.na(NevusFeatures))
sum(is.na(MelanomaControlFeatures))
sum(is.na(NevusControlFeatures))

channel1 <- c(1:32)
channel2 <- c(33:64)
channel3 <- c(65:96)

MMelanomaFeatures <- ( MelanomaFeatures[,channel1] +
                      MelanomaFeatures[,channel2] +
                      MelanomaFeatures[,channel3] )/3.0
SMelanomaFeatures <- ( abs(MelanomaFeatures[,channel1] - MMelanomaFeatures) +
                      abs(MelanomaFeatures[,channel2] - MMelanomaFeatures) +
                      abs(MelanomaFeatures[,channel3] - MMelanomaFeatures) )/3.0

colnames(MMelanomaFeatures) <- paste("M",colnames(MMelanomaFeatures),sep="")
colnames(SMelanomaFeatures) <- paste("S",colnames(SMelanomaFeatures),sep="")

MelanomaFeatures <- cbind(MelanomaFeatures,SMelanomaFeatures/(0.01+abs(MMelanomaFeatures)))

```

*Fig 2. Data Conditioning.*

Se utiliza un *'Heat Map'* para evaluar los datos obtenidos, que serán implementados en cuatro diferentes métodos de análisis por computadora, con el objetivo de evaluar el desempeño de cada uno de estos. Los métodos a analizar son los siguientes: KNN, SVM, Naive Bayes con PCA y LASSO. Se utilizó una gráfica para evaluar el desempeño de cada uno de los métodos.

```
performace <- predictionStats_binary(cvLASSO$medianTest,"LASSO")
```

*Fig 3. Plot performance.*

## Resultados y discusión

### *Segmentación de Lesiones de Piel*

La segmentación de las lesiones de piel es una etapa crucial en el análisis de imágenes médicas. La calidad de la segmentación afecta directamente la precisión de las características extraídas y, por ende, la efectividad de los modelos de clasificación.

Las imágenes que se encuentran correctamente segmentadas (Fig. 4), presentan las siguientes características. La lesión está claramente aislada del fondo, las características extraídas reflejan de manera precisa los atributos de la lesión. Esto facilita que los modelos de clasificación como SVM y KNN distingan entre melanoma y otras lesiones con mayor precisión. Una buena segmentación asegura que los datos utilizados para entrenar los modelos no estén contaminados por información irrelevante, mejorando la generalización del modelo.

Por otro lado, las imágenes con mala segmentación (Fig. 5) presentan ruido y datos irrelevantes que pueden confundir al modelo. Por ejemplo, la inclusión de piel sana o sombras puede alterar los valores de características de textura y forma, llevando a clasificaciones incorrectas. Este tipo de segmentación deficiente puede disminuir la sensibilidad y especificidad de los modelos, ya que los patrones aprendidos no representan correctamente las lesiones que se quieren clasificar.

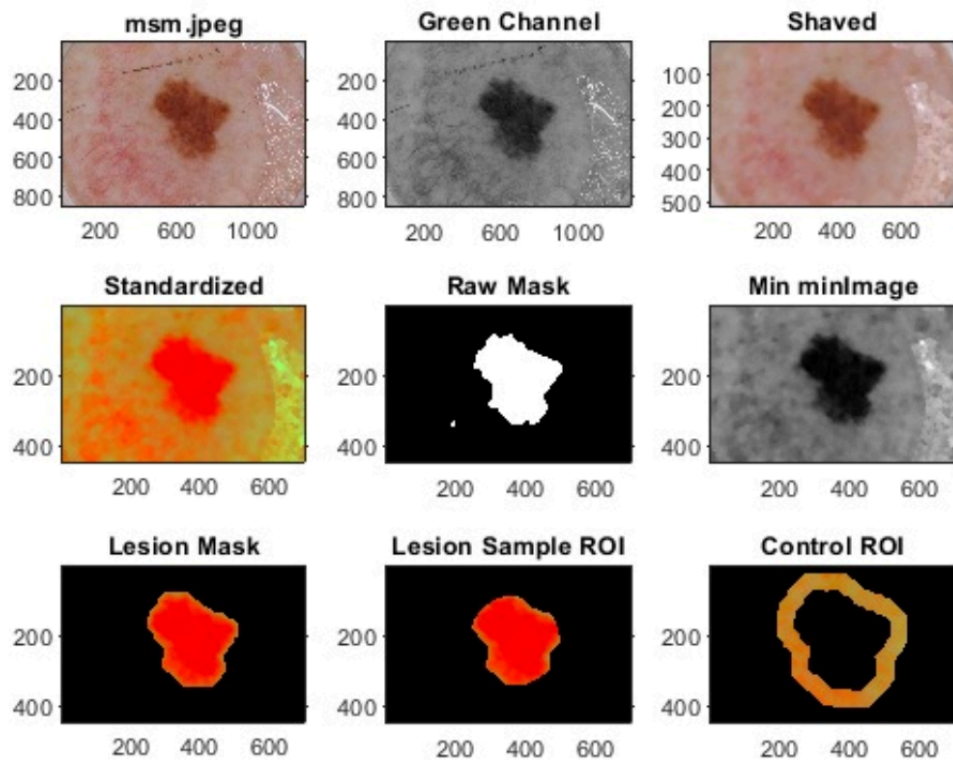


Fig 4. Ejemplo de una buena segmentación de imagen de melanoma.

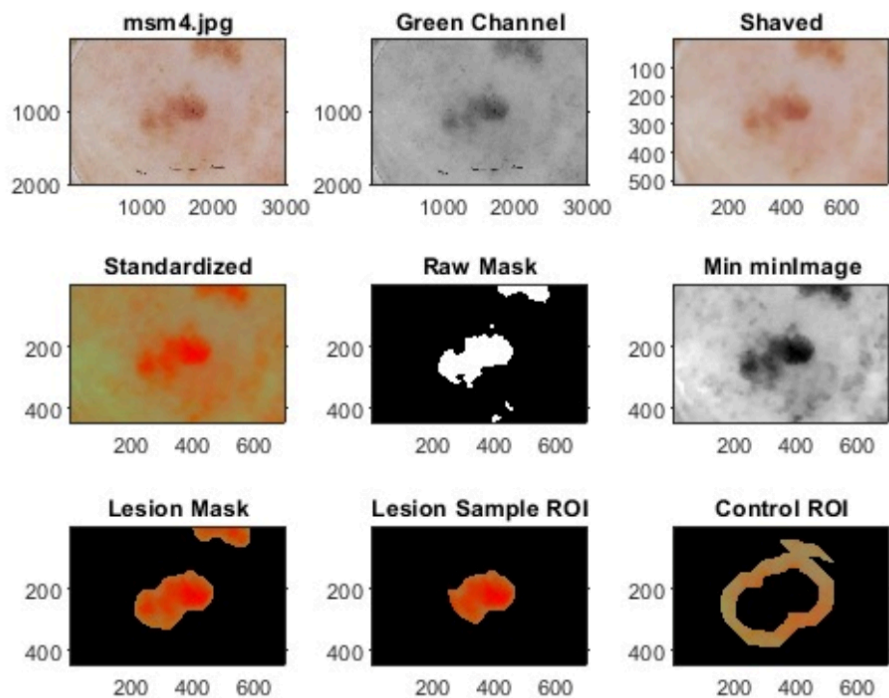


Fig 5. Ejemplo de una mala segmentación de imagen de melanoma.



## Extracción de Características

Las características extraídas de las imágenes segmentadas son fundamentales para el rendimiento de los modelos de aprendizaje automático.

### Señal

La media, desviación estándar, skewness y kurtosis proporcionan una descripción estadística básica de la intensidad de los píxeles. Estas características son útiles para diferenciar entre lesiones más oscuras y más claras, pero pueden ser insuficientes para capturar la complejidad de las texturas presentes en las lesiones de melanoma.




Fig 6. Histograma de intensidad media por clase




Fig 7. Histograma de la desviación estándar por clase

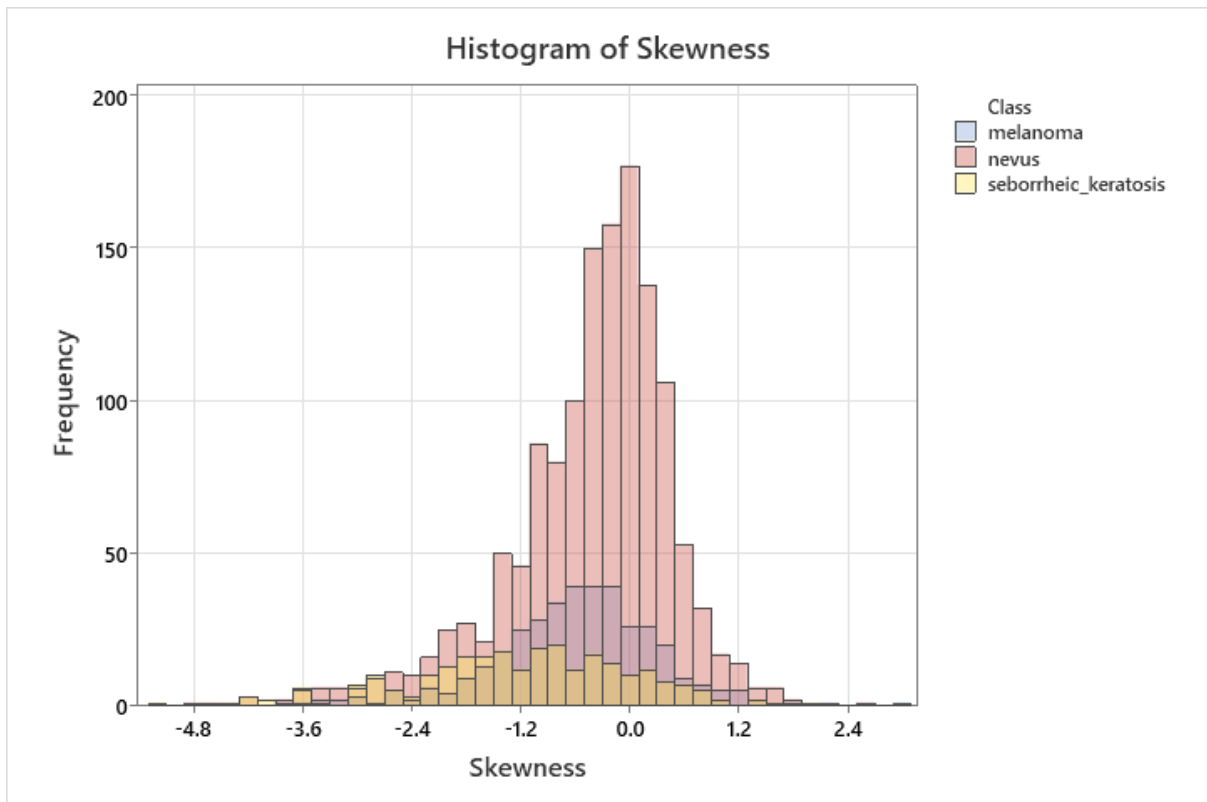
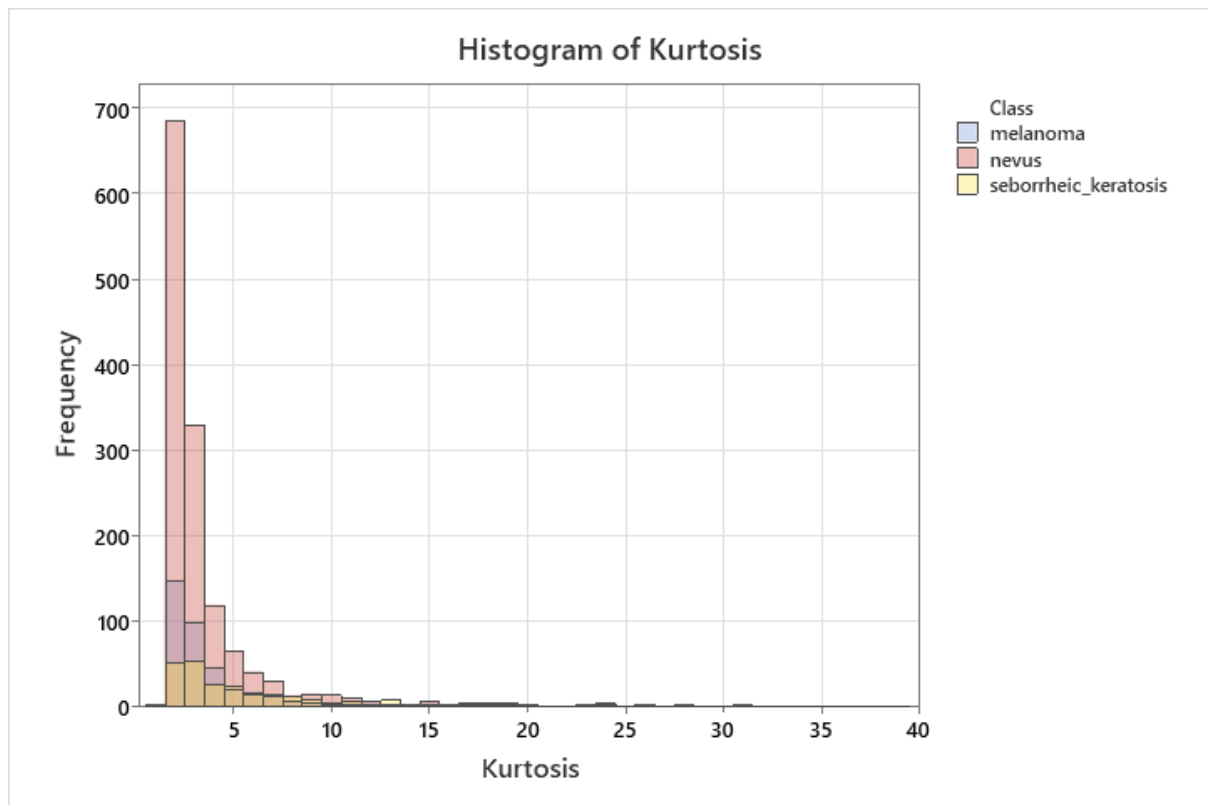


Fig 8. Histograma de oblicuidad por clase



*Fig 9. Histograma de Kurtosis por clase.*

Las gráficas muestran que las imágenes de melanomas tienden a tener una media de intensidad de píxeles más alta en comparación con las lesiones benignas, lo que sugiere que los melanomas podrían ser más oscuros en promedio. La desviación estándar es más alta en melanomas, indicando mayor variabilidad en la intensidad de los píxeles, lo cual podría reflejar la heterogeneidad de los melanomas.

Las gráficas de skewness muestran una tendencia hacia valores positivos en melanomas, proponiendo que las distribuciones de intensidad tienden a ser sesgadas a la derecha. La kurtosis es mayor en melanomas, lo que sugiere distribuciones con picos más altos y colas más largas, indicativas de la presencia de áreas con intensidades extremas.

## Forma

El estudio de forma es fundamental en la detección temprana y el diagnóstico preciso de melanomas. Comprender y analizar la forma, el área y la excentricidad puede ayudar a los médicos a identificar melanomas en etapas más tempranas, lo que mejora significativamente las tasas de supervivencia y los resultados para los pacientes.


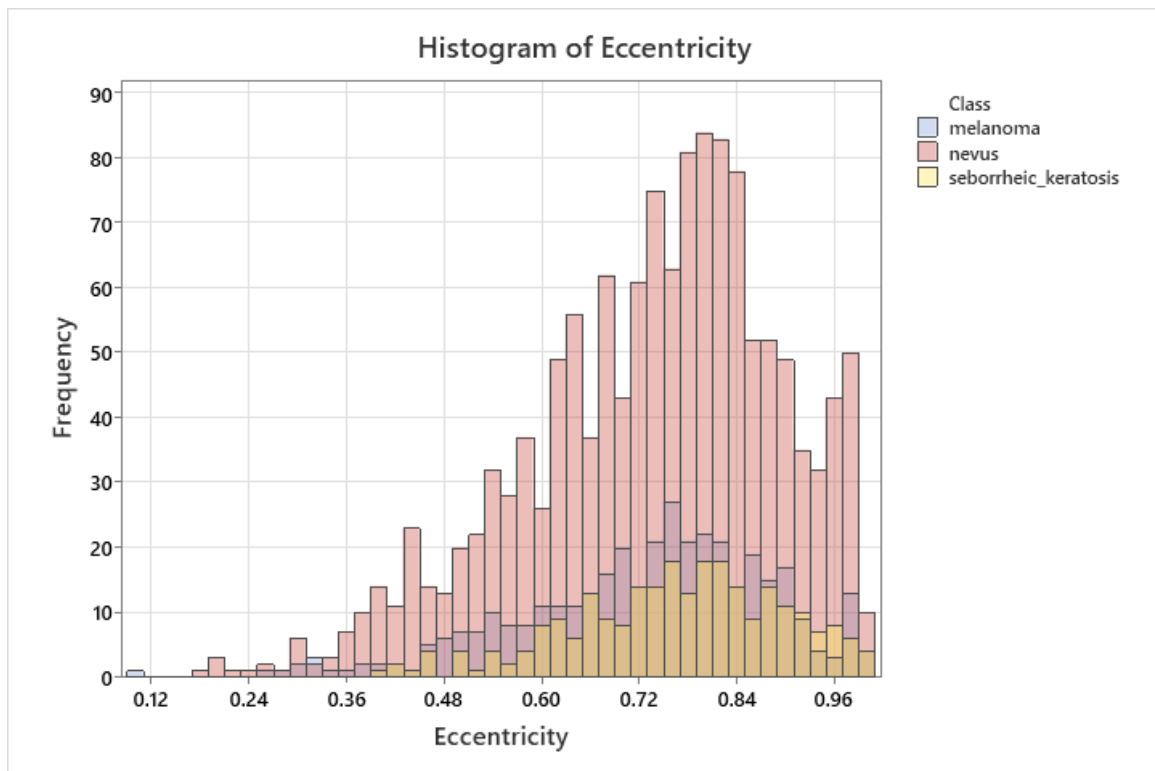


Fig 10. Histograma del área por clase



*Fig 11. Histograma de excentricidad por clase.*

Los melanomas generalmente tienen un mayor volumen y superficie en comparación con otras lesiones, como se refleja en las gráficas. Esto indica que los melanomas tienden a ser más grandes y ocupar más espacio en la imagen.

### *Textura*

Las características de textura son cruciales. Las gráficas pueden mostrar diferencias significativas en la homogeneidad, contraste y correlación de textura entre melanomas y otras lesiones. Estas diferencias reflejan la estructura interna compleja y heterogénea de los melanomas.

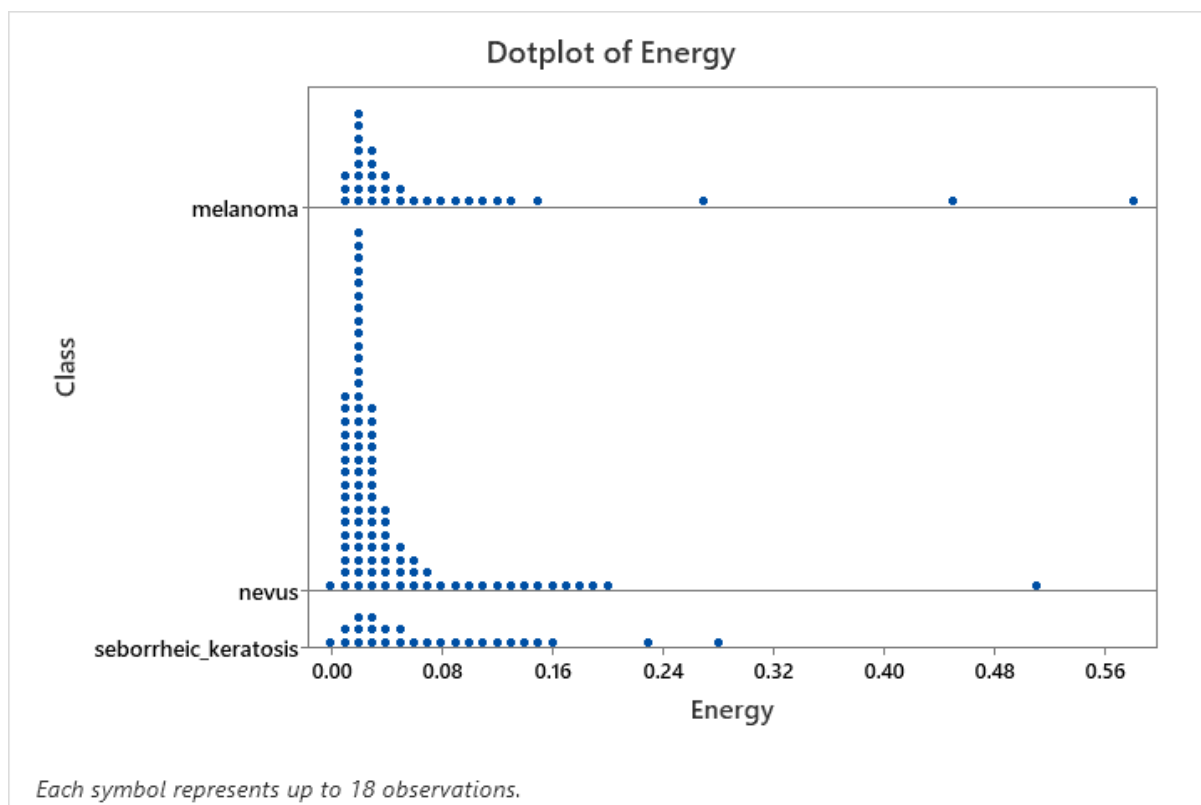


Fig 12. Gráfica de puntos de energía por clase.




Fig 13. Gráfica de puntos de entropía por clase

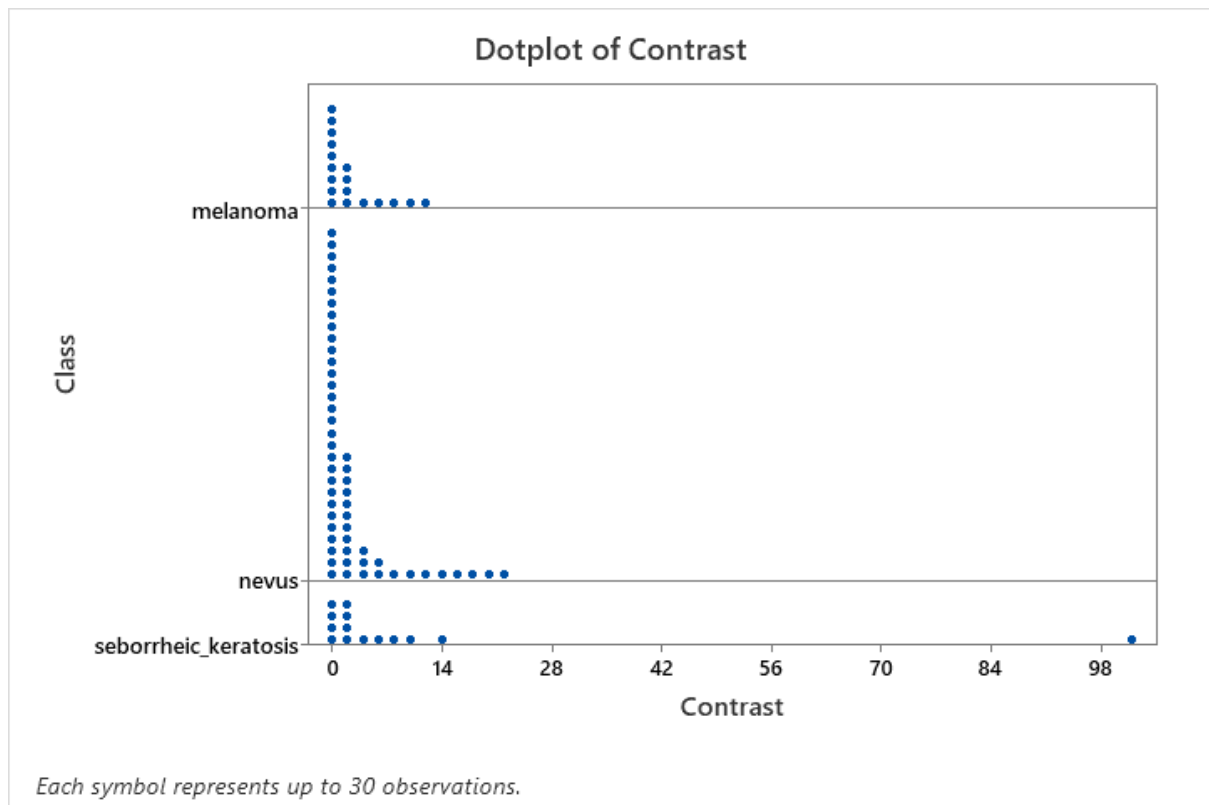


Fig 14. Gráfica de puntos de contraste por clase




Fig 15. Gráfica de puntos de correlación por clase




Fig 16. Gráfica de puntos de homogeneidad por clase

Las características de GLCM y Haralick muestran que los melanomas tienen valores más altos de contraste y menos homogeneidad, lo que indica una textura más compleja y variada. Los valores de energía y correlación son menores en melanomas, sugiriendo menos uniformidad y más variación en la textura.

### *Dimensiones Fractales*

Las gráficas pueden mostrar que los melanomas tienen dimensiones fractales más altas, indicando bordes más complejos y detallados en comparación con otras lesiones.



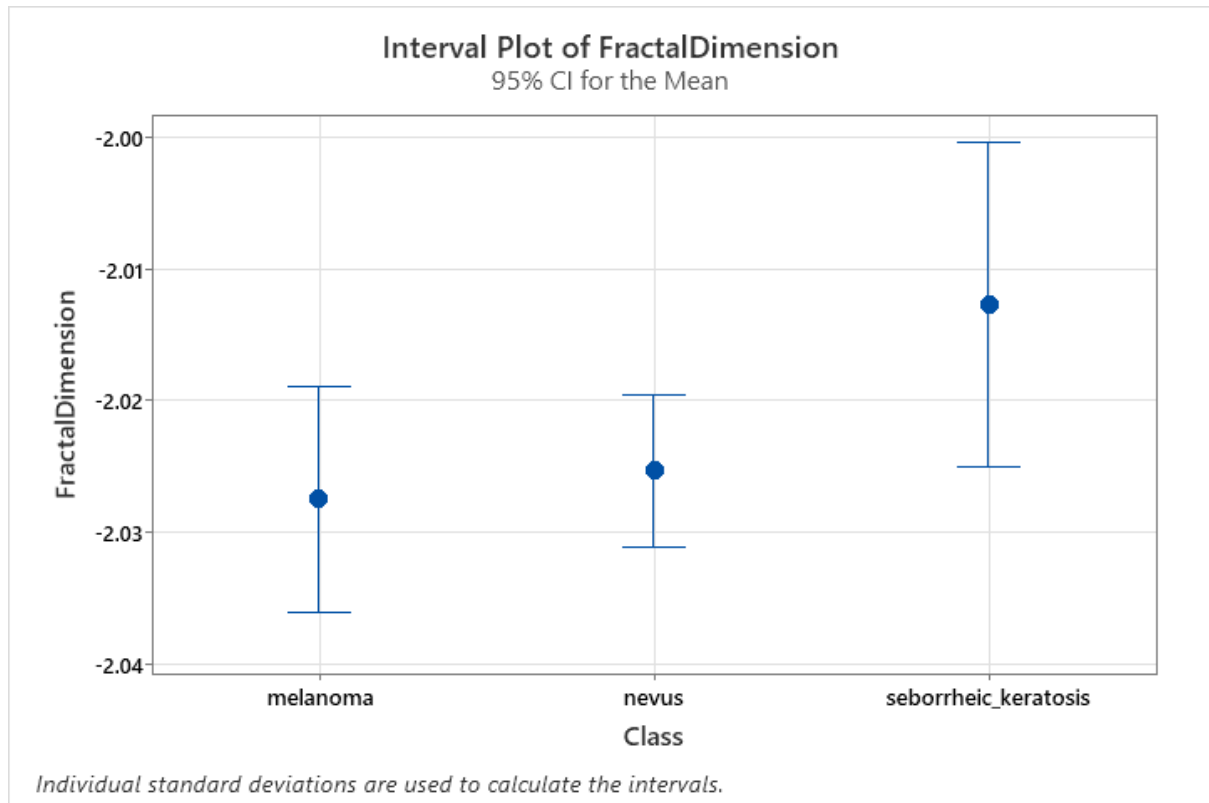


Fig 17. Gráfica de intervalo de dimensión fractal

Las gráficas de dimensiones fractales muestran que los melanomas tienen dimensiones fractales más altas, lo que refleja una mayor complejidad e irregularidad en sus formas. Esta característica es particularmente útil para identificar melanomas debido a sus bordes notoriamente irregulares y complejos, que son difíciles de capturar con características de forma simples como el volumen y la superficie.

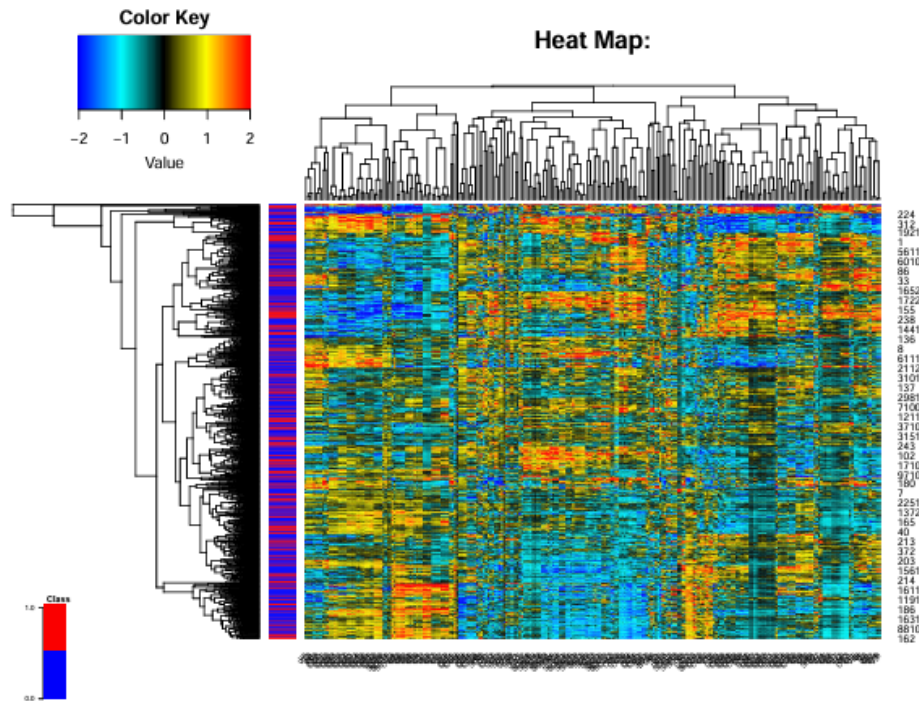


Fig 18. Distribución de las características en las imágenes.

### Algoritmos de aprendizaje supervisado




Fig 19. Resultado del entrenamiento del algoritmo de clasificación KNN.




Fig 20.Resultado del entrenamiento del algoritmo de clasificación SVM.




Fig 21. Resultado del entrenamiento del algoritmo de clasificación NB .

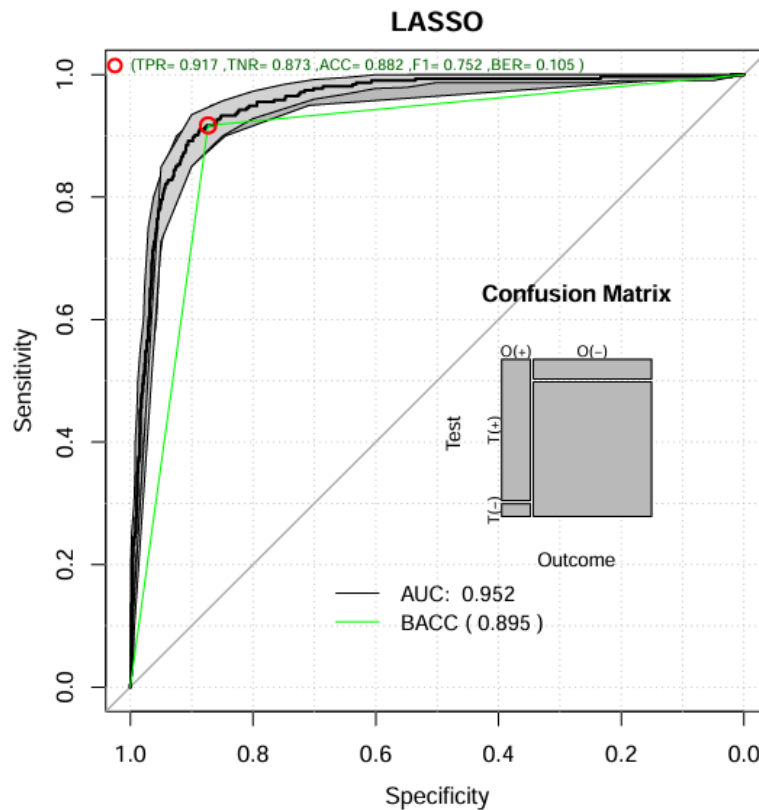


Fig 22. Resultado del entrenamiento del algoritmo de clasificación LASSO .

Los modelos de aprendizaje automático, como KNN, SVM, LASSO y Naive Bayes, han sido evaluados exhaustivamente en la clasificación de melanoma, utilizando diversas métricas y herramientas de evaluación. KNN, a pesar de su simplicidad, ha demostrado un rendimiento aceptable en sensibilidad y especificidad, aunque su precisión puede ser afectada por ruidos y outliers, siendo crucial la elección de parámetros como K y la distancia utilizada.

Por otro lado, SVM ha destacado como uno de los modelos más efectivos, gracias a su capacidad para manejar espacios de alta dimensión y encontrar el hiperplano óptimo de separación, atribuyendo su éxito a la selección adecuada de parámetros de kernel y regularización.

LASSO ha mejorado la interpretabilidad al reducir características, aunque su precisión puede ser ligeramente inferior a la de SVM, especialmente en conjuntos de datos complejos. En contraste, Naive Bayes, a pesar de su eficiencia, puede tener un rendimiento subóptimo al hacer suposiciones sobre la independencia de características.

La evaluación mediante matrices de confusión y curvas ROC ha revelado que tanto SVM como LASSO tienen una mejor capacidad para discriminar entre melanoma y otras

lesiones, con áreas bajo la curva más altas, indicando una mejor capacidad predictiva. La segmentación precisa de las lesiones y la extracción de características diversas son fundamentales para mejorar la precisión, especialmente en la captura de características de textura y dimensiones fractales, donde modelos avanzados como SVM y LASSO han mostrado un rendimiento superior.

En contraste, modelos como KNN y Naive Bayes han sido menos efectivos debido a sus limitaciones en el manejo de la complejidad de características y dependencia de supuestos simplistas. En resumen, SVM y LASSO destacan por su capacidad para manejar datos complejos y multidimensionales, reflejado en su alto rendimiento en sensibilidad, especificidad y F1-score.

## **Conclusiones**

**Naomi De la Cruz García.**

Actualmente existen diversos algoritmos de aprendizaje por computadora que pueden ser entrenados para la clasificación de características, los cuales han sido aplicados en el área médica para mejorar y hacer más preciso el diagnóstico de lesiones en la piel, como los melanomas (Esteva et al., 2017). En este estudio se han entrenado cuatro algoritmos diferentes para la clasificación de características, de los cuales el SVM y LASSO mostraron mayor rendimiento en sensibilidad y F1-score, esto se relaciona a su capacidad de procesar datos de alta dimensión, como en este caso, una matriz con muchas características e imágenes (Muthukrishnan & Rohini, 2016; Sen et al., 2020).

**Juan Jose Robalino Romo Leroux.**

La evaluación de diversos modelos de aprendizaje automático en la clasificación de melanoma ha revelado que SVM y LASSO destacan por su capacidad para manejar datos complejos y multidimensionales, obteniendo un alto rendimiento en sensibilidad, especificidad y F1-score. Estos modelos han demostrado ser eficaces en la discriminación entre melanoma y otras lesiones cutáneas, lo que los convierte en opciones prometedoras para aplicaciones clínicas. Sin embargo, se debe tener en cuenta las limitaciones de cada modelo y la importancia de la adecuada selección de características y parámetros para obtener resultados óptimos.

### **Astrid Geraldine Serna Zazueta.**

La segmentación de imágenes representa una gran parte para el procesamiento y clasificación de imágenes médicas, con las cuales se puede lograr dar un diagnóstico adecuado y oportuno que ayude a mejorar la calidad de vida y tratamiento de los pacientes. En el presente reporte se llevaron a cabo cuatro tipos diferentes de clasificadores de imágenes y se evaluó su eficacia para dar un diagnóstico correcto, lo que es útil para entender sobre el procesamiento que se lleva a cabo y cuáles son las características más valiosas en un software de imágenes médicas.

### **Roberto Rodríguez Sanchez.**

En este estudio se evaluaron 4 algoritmos de aprendizaje automático para la clasificación de melanoma y otras imágenes cutáneas a partir de una serie de imágenes, los resultados demuestran la importancia de una correcta segmentación de imágenes y extracción de características para mejorar la precisión de los modelos de aprendizaje automático. En cuanto al desempeño de los 4 modelos, podemos observar que los modelos SVM y LASSO demostraron tener una mejor capacidad predictiva, indicando una mayor capacidad para diferenciar entre el melanoma y otras lesiones, además, las matrices de confusión indican una mayor sensibilidad y F1 score en comparación con los 2 modelos restantes. Es necesario resaltar la importancia del uso de algoritmos de aprendizaje en el diagnóstico temprano del melanoma y un tratamiento más efectivo.

### **Referencias**

Anderson J, Parikh J, Shenfeld D. Reverse Engineering and Evaluation of Prediction Models for Progression to Type 2 Diabetes: Application of Machine Learning Using Electronic Health Records. J Diabetes. 2016.

Bhatt, H., Shah, V., Shah, K., Shah, R. and Shah, M. (2023). State-of-the-art machine learning techniques for melanoma skin cancer detection and classification: a comprehensive review. *Intelligent medicine*, [online] 3(3), pp.180–190. doi:<https://doi.org/10.1016/j.imed.2022.08.004>.

Celebi, M. E., Codella, N., & Halpern, A. (2019). Dermoscopy Image Analysis: Overview and Future Directions. *IEEE journal of biomedical and health informatics*, 23(2), 474–478. doi:10.1109/jbhi.2019.2895803

C. González-Cruz, Jofre, M.A., S. Podlipnik, M. Combalia, Gareau, D., Gamboa, M., Vallone, M.G., Z. Faride Barragán-Estudillo, A.L. Tamez-Peña, Montoya, J., M. América Jesús-Silva, Carrera, C., J. Malveyh and Puig, S. (2020). Uso del aprendizaje automático en el diagnóstico del melanoma. Limitaciones por superar. *Actas dermo-sifiliográficas/Actas dermo-sifiliográficas*, [online] 111(4), pp.313–316. doi:https://doi.org/10.1016/j.ad.2019.09.002.

Curti B.D., Vetto J.T., & Leachman S.A. (2022). Cáncer de la piel. Loscalzo J, & Fauci A, & Kasper D, & Hauser S, & Longo D, & Jameson J(Eds.), *Harrison. Principios de Medicina Interna*, 21e. McGraw-Hill Education. https://0-accessmedicina-mhmedical-com.biblioteca-ils.tec.mx/content.aspx?bookid=3118&sectionid=267819136

D’Orazio, J., Jarrett, S., Amaro-Ortiz, A., & Scott, T. (2013). UV radiation and the skin. *International Journal of Molecular Sciences*, 14(6), 12222–12248. https://doi.org/10.3390/ijms140612222

Esteva, E. (2007). Melanoma. *Offarm*, 26(8), 68–73. Recuperado de https://www.elsevier.es/es-revista-offarm-4-articulo-melanoma-13109815

Esteva, A., Kuprel, B., Novoa, R. *et al.* Dermatologist-level classification of skin cancer with deep neural networks. *Nature* **542**, 115–118 (2017). https://doi.org/10.1038/nature21056

Mohri, M., Rostamizadeh, A., & Talwalkar, A. (2018). *Foundations of machine learning*. MIT press.

Muthukrishnan, R., & Rohini, R. (2016). LASSO: A feature selection technique in predictive modeling for machine learning. *2016 IEEE International Conference on Advances in Computer Applications (ICACA)*.

Osisanwo, F. Y., Akinsola, J. E. T., Awodele, O., Hinmikaiye, J. O., Olakanmi, O., & Akinjobi, J. (2017). Supervised machine learning algorithms: classification and comparison. *International Journal of Computer Trends and Technology (IJCTT)*, 48(3), 128-138.

- Palacios-Martínez, D., & Díaz-Alonso, R. A. (2017). Dermatoscopia para principiantes ( i ): características generales. *Semergen*, 43(3), 216–221. doi:10.1016/j.semerg.2015.11.009
- Proksch, E., Brandner, J. M., & Jensen, J.-M. (2008). The skin: an indispensable barrier. *Experimental Dermatology*, 17(12), 1063–1072. <https://doi.org/10.1111/j.1600-0625.2008.00786.x>
- Rigel, D. S., & Carucci, J. A. (2000). Malignant melanoma: prevention, early detection, and treatment in the 21st century. *CA: A Cancer Journal for Clinicians*, 50(4), 215–236. doi:10.3322/canjclin.50.4.215
- Saravanan, R., & Sujatha, P. (2018). A state of art techniques on machine learning algorithms: A perspective of supervised learning approaches in data classification. *2018 Second International Conference on Intelligent Computing and Control Systems (ICICCS)*.
- Senan, E. M., & Jadhav, M. E. (2021). Analysis of dermoscopy images by using ABCD rule for early detection of skin cancer. *Global Transitions Proceedings*, 2(1), 1–7. doi:10.1016/j.gltp.2021.01.001
- Sen, P. C., Hajra, M., & Ghosh, M. (2020). Supervised classification algorithms in machine learning: A survey and review. En *Advances in Intelligent Systems and Computing* (pp. 99–111). Springer Singapore.